

Designspecifikation: Executive Insights (Alternativ 1)

Serverlös & Kostnadseffektiv Arkitektur för Arkivbaserad RAG-analys

Detta dokument fastställer designspecifikationen för en kostnadseffektiv prototypmiljö ("Alternativ 1") avsedd för *Executive Insights*. Systemet transformerar mötetstranskriptioner, extraherar affärsvertikaler samt horisontella beroenden, kopplar aktiviteter till specifika individer, samt möjliggör semantisk och strategisk analys via en anpassad Copilot-klient (LLM).

1. Systemarkitektur & Dataflöde

Arkitekturen minimerar fasta molnkostnader under valideringsfasen genom att ersätta tunga hanterade söktjänster med ett lokalt/serverlöst vektorindex (ChromaDB/FAISS) kombinerat med standardiserad lagring på SharePoint.

Steg	Komponent / Process	Utdata / Format
1. Preprocessor	Python-skript / Azure Function kör text-parsing, namngiven entitetsigenkänning (NER) samt LLM-baserad beroendeextraktion.	Strukturerad JSON-fil (Metadata + Chunk-text).
2. Lagring	Överföring till centralt dokumentbibliotek på SharePoint för långtidsarkivering och versionshantering.	Arkiverad JSON i SharePoint-mappstruktur.
3. Indexering	Vektorisering via Azure OpenAI Embedding API samt lokal lagring i ChromaDB/FAISS (vektordatabas som platt fil).	Lokala indexfiler (.bin / SQLite).
4. Analys & Gränssnitt	Anpassat RAG-gränssnitt (t.ex. Streamlit eller lokal Teams-app) som kör hybrid sökning och levererar data till GPT-4o.	Genererade strategiska insikter och summeringar.

2. Konfiguration av Preprocessor (Datamodell)

Preprocessorn konfigureras att leverera en strikt validerad JSON-struktur. Detta garanterar att den efterföljande indexeringen kan separera metadata (för hårda filter) från fritext (för semantisk vektorsökning).

JSON-Schema för utdata

```
{
  "meeting_id": "UUID-v4 string",
  "title": "str (t.ex. 'Ledningsgrupp Q3 synk')",
  "date": "YYYY-MM-DD",
  "participants": [
    {
      "name": "str",
      "email": "str (UPN)"
    }
  ]
}
```

```

],
"verticals": ["Sälj", "Produkt", "HR", "Marknad"],
"dependencies": [
  {
    "source_vertical": "str",
    "target_vertical": "str",
    "description": "str (Beskrivning av beroendet)",
    "impact_level": "High|Medium|Low"
  }
],
"action_items": [
  {
    "task": "str",
    "assignee_email": "str (UPN)",
    "due_date": "YYYY-MM-DD|null"
  }
],
"chunks": [
  {
    "chunk_id": "int",
    "text": "str (Rent, preprocessat textstycke, max 1000 tecken)",
    "referenced_verticals": ["str"]
  }
]
}

```

3. Lagringsstrategi (SharePoint)

För att säkerställa spårbarhet och framtida integrationer sparas filerna i ett strukturerat SharePoint-dokumentbibliotek. Sökvägsstrukturen bygger på datum och vertikal fokus för att förenkla manuell revision:

```

Shared Documents/ExecutiveInsights_Repo/
├── 2026/
│   ├── 07 (Juli)/
│   │   ├── 2026-07-05_Sälj_Produkt_Synk.json
│   │   └── 2026-07-06_HR_Ledningsgrupp.json

```

Viktigt gällande SharePoint API

I prototypstadiet kan filerna laddas upp via Microsoft Graph API eller synkroniseras lokalt till preprocessorns exekveringsmiljö via OneDrive/SharePoint-klienten för att helt undvika komplex autentiseringslogik i fas 1.

4. Indexeringsarkitektur (Serverlös Vektordatabas)

Istället för att betala för en ständigt igångvarande molndatabas används **ChromaDB** eller **FAISS** i filbaserat läge. Indexeringen sker asynkront eller batchvis.

Processbeskrivning:

1. När en ny JSON-fil genererats, läser indexeringsskriptet igenom arrayen chunks.

2. Varje textchunk skickas till Azure OpenAI:s modell text-embedding-3-small (eller text-embedding-3-large för djupare strategiska textkopplingar).
3. Vektor-embeddingen sparas i det lokala indexet tillsammans med tillhörande metadata (meeting_id, date, verticals, assignee_email).
4. Hela index-databasen sparas ner som en samling filer på disk (eller i en billig Azure Blob Storage-container som laddas ner vid behov).

5. Analysmotor & RAG-Pipeline

När en chef ställer en strategisk fråga (t.ex. *"Vilka horisontella beroenden mellan Sälj och Produkt har diskuterats under de senaste 30 dagarna?"*) exekveras följande trestegsraket:

Steg A: Query Transformation & Filtrering

Frågan analyseras för att utvinna tidsfilter (senaste 30 dagarna) samt kategorifilter (verticals IN ['Sälj', 'Produkt']).

Steg B: Semantisk Sökning (ChromaDB/FAISS)

Användarens fråga vektoriseras och databasen gör en cosinus-likhetssökning *enbart* på de dokument som matchar metadata-filtren. De topp K (t.ex. 10 mest relevanta) textchunkarna samt beroendematriserna hämtas.

Steg C: LLM-Generering (GPT-4o)

Den extraherade datan formateras till en prompt och skickas till GPT-4o som formulerar det slutgiltiga strategiska svaret.

Promptmall för Systemanalys (System Prompt)

Du är en Executive Insights Assistant. Din uppgift är att analysera preprocessad mötesdata och ge strategiska, kärnfulla svar till företagsledningen.

Följande datakontext har hämtats från relevanta möten:
[KONTEXT FRÅN VEKTORDATABAS]

Instruktioner:

1. Identifiera alltid horisontella beroenden och potentiella flaskhalsar.
2. Koppla specifika ärenden och ansvar till namngivna personer baserat på 'action_items'.
3. Om information saknas för att dra en strategisk slutsats, var transparent med det.
4. Svara strukturerat med rubriker och punktlistor.

6. Kostnads kalkyl: Prototyp vs. Produktion

Nedan visas en uppskattning över de månatliga infrastrukturkostnaderna under prototypfasen (Alternativ 1) jämfört med produktion med Azure AI Search.

Resurstyp	Alternativ 1 (Prototyp - ChromaDB/FAISS)	Standard Azure RAG (Azure AI Search)
	0 kr (Filbaserad lagring i Azure Blob / Lokalt)	

Resurstyp	Alternativ 1 (Prototyp - ChromaDB/FAISS)	Standard Azure RAG (Azure AI Search)
Sökindex / Databas		ca 2 500 - 5 000 kr/mån (Basic/Standard instans)
Embeddings & LLM	Rörlig kostnad per token (ca 50 - 200 kr/mån vid testning)	Rörlig kostnad per token (samma)
Lagring	Ingår i befintlig SharePoint/M365-licens	Ingår i befintlig SharePoint/M365-licens
Totalt (Estimerat)	~50 - 200 kr / månad	~2 550 - 5 200 kr + / månad